

Proyecto de Deep Learning: Clasificación de Imágenes (Bart vs Homero)

Informe Final — Segunda Entrega

1. Contexto de aplicación

En el ámbito de la visión por computador, el desarrollo de modelos de clasificación de imágenes suele implicar altos requerimientos computacionales y grandes volúmenes de datos. Sin embargo, en contextos de experimentación y desarrollo incremental, resulta conveniente iniciar con problemas acotados que permitan validar rápidamente arquitecturas, flujos de procesamiento y estrategias de entrenamiento.

En este proyecto se aborda un problema de clasificación binaria utilizando imágenes de Bart y Homero Simpson. Gracias a la simplicidad visual de estos personajes; colores planos, siluetas características, este dominio permite construir una primera implementación funcional con un coste computacional reducido y facilitar la iteración rápida sobre el modelo. A partir de esta base se incorporaron mejoras progresivas sin necesidad de redefinir completamente la arquitectura.

2. Objetivo de Machine Learning

El objetivo es desarrollar un modelo de deep learning capaz de clasificar imágenes de Bart y Homero Simpson. El problema se formula como una función $f(x) \rightarrow y$, donde x es una imagen RGB e y es una etiqueta binaria (0 = Bart, 1 = Homero).

Adicionalmente, se busca establecer un entorno experimental que permita evaluar de forma iterativa el impacto de distintas técnicas sobre el desempeño: variaciones en la arquitectura, estrategias de regularización, data augmentation y transfer learning.

3. Dataset

El dataset utilizado es **Homer & Bart Classification**, disponible en Kaggle (*juniorbueno/neural-networks-homer-and-bart-classification*). Contiene aproximadamente 270 imágenes en formato BMP, con un peso total de 132 MB, distribuidas de forma aproximadamente balanceada entre las dos clases. Las imágenes presentan a los personajes en diversas situaciones con variabilidad en fondo e iluminación.

Todas las imágenes se encuentran en una carpeta plana sin subdirectorios; la etiqueta de clase se extrae del nombre del archivo (p. ej. bart_001.bmp, homer_042.bmp).

Obtención del dataset. Los notebooks descargan automáticamente el dataset usando la API de Kaggle. El único requisito previo es disponer de un archivo *kaggle.json* si se busca ejecutar en local.

Característica	Valor
Total de imágenes	270
Formato	BMP, carpeta plana sin subdirectorios
Clases	Bart (0) / Homero (1)
Balance de clases	Aproximadamente balanceado
División entrenamiento	70 % (~190 imágenes)
División validación	15 % (~40 imágenes)
División test	15 % (~40 imágenes)
Resolución entrada (baseline)	128 × 128 px
Resolución entrada (TL)	160 × 160 px

Tabla 1. Características principales del dataset.

El tamaño reducido del dataset (190 imágenes de entrenamiento) representa el principal desafío del proyecto: el riesgo de sobreajuste es elevado al entrenar una CNN desde cero, lo que motivó el uso de técnicas de regularización, data augmentation y, finalmente, transfer learning.

4. Descripción de los notebooks

La solución se organiza en dos notebooks numerados que implementan la solución de forma progresiva. Ambos son directamente ejecutables en Google Colab sin modificaciones adicionales.

Notebook	Descripción	Secciones principales
01_baseline_cnn.ipynb	CNN entrenada desde cero. Sirve como referencia (baseline) para medir el impacto de las mejoras posteriores.	- Descarga - Preprocesado - Arquitectura CNN - Entrenamiento - Evaluación - Visualización de predicciones
02_mejoras_Data_Augmentation_Transfer_Learning.ipynb	Mejoras sobre el baseline: data augmentation ampliado, transfer learning con MobileNetV2 en dos fases y análisis Grad-CAM.	- Descarga - Preprocesado - Augmentation - Fase 1 (backbone congelado) - Fase 2 (fine-tuning) - Evaluación - ROC - Grad-CAM - Comparativa

Tabla 2. Resumen de los notebooks entregados.

5. Descripción de la solución

5.1 Preprocesado común a ambos notebooks

Las imágenes se leen con `tf.image.decode_bmp` y se redimensionan al tamaño de entrada requerido por cada modelo. La elección de tamaños diferentes responde a las restricciones de cada arquitectura: 128×128 px para la CNN baseline (sin restricción mínima) y 160×160 px para MobileNetV2, que requiere al menos 96×96 px y se beneficia de mayor resolución para capturar detalles finos de los personajes.

La normalización difiere entre modelos. Para la CNN baseline se lleva el rango de píxeles a $[0, 1]$, convención habitual al entrenar desde cero. Para MobileNetV2 se aplica la normalización propia del backbone $[-1, 1]$, necesaria para que las estadísticas de las activaciones sean coherentes con las vistas durante el preentrenamiento en ImageNet; usar una normalización distinta degradaría las representaciones aprendidas.

La división en conjuntos se realiza de forma estratificada en ambos notebooks para mantener la proporción de clases en cada partición, lo cual es especialmente importante con un dataset tan pequeño.

5.2 Notebook 01 — CNN baseline

La arquitectura sigue el patrón Conv2D $\rightarrow$ BatchNormalization $\rightarrow$ Relu $\rightarrow$ MaxPooling2D, repetido en tres bloques con 32, 64 y 128 filtros respectivamente. Este patrón extrae features de complejidad creciente de forma progresiva, mientras que BatchNormalization estabiliza el entrenamiento reduciendo el problema del desvanecimiento del gradiente.

Componente	Configuración	Justificación
Input	$128 \times 128 \times 3$	Resolución suficiente para personajes simples; menor coste computacional que 224×224 .
Augmentation	Flip H · Rotación $\pm 10\%$ · Zoom $\pm 10\%$	Regularización básica; incrementa la variedad efectiva sin distorsionar la forma de los personajes.
Bloque Conv 1	Conv2D(32, 3×3) + BN + ReLU + MaxPool(2)	32 filtros para features de bajo nivel (bordes, colores planos).
Bloque Conv 2	Conv2D(64, 3×3) + BN + ReLU + MaxPool(2)	64 filtros para features intermedios (formas, contornos).
Bloque Conv 3	Conv2D(128, 3×3) + BN + ReLU + MaxPool(2)	128 filtros para features de alto nivel (partes del personaje).
Clasificador	Flatten $\rightarrow$ Dense(128, ReLU) $\rightarrow$ Dropout(0.5) $\rightarrow$ Dense(2, Softmax)	Dropout 0.5 penaliza los pesos grandes de neuronas, reduciendo el sobreajuste.
Optimizador	lr = $1e-3$	Convergencia adaptativa; lr estándar para CNN entrenada desde cero.

Componente	Configuración	Justificación
Loss	Sparse Categorical Crossentropy	Pérdida adecuada para clasificación multiclase con etiquetas enteras.
Batch size	4	Dataset muy pequeño; batch pequeño maximiza los pasos de gradiente por época.
Épocas máx.	30 con EarlyStopping (patience = 12)	Paciencia alta por la varianza elevada de validación con ~40 muestras.

Tabla 3. Arquitectura y decisiones de diseño de la CNN baseline.

5.3 Notebook 02 — Transfer Learning con MobileNetV2

Se eligió MobileNetV2 como backbone por dos razones. Primero, su preentrenamiento en ImageNet (1.28 millones de imágenes, 1000 clases) proporciona representaciones visuales ricas que compensan la escasez de datos propios. Segundo, su arquitectura de *depthwise-separable convolutions* lo hace computacionalmente eficiente y viable en Google Colab sin GPU dedicada.

El entrenamiento se organiza en dos fases:

- **Fase 1 — Backbone congelado:** únicamente se entrena la nueva cabeza clasificadora. Esta fase es rápida y estable; el clasificador aprende a interpretar los features del backbone sin interferir en sus pesos. Se usa $lr = 1e-3$ durante un máximo de 15 épocas.
- **Fase 2 — Fine-tuning parcial:** se descongela la parte superior del backbone (las últimas 54 de 154 capas) y se reentrena con $lr = 1e-4$, diez veces menor. Descongelar solo las capas superiores; que detectan patrones de alto nivel específicos del dominio permite adaptar el backbone al estilo visual de Los Simpsons sin destruir los features genéricos de las capas inferiores.

Componente	Configuración	Justificación
Input	$160 \times 160 \times 3$	Mínimo recomendado para MobileNetV2; mayor resolución mejora la captura de detalles finos.
Augmentation	Flip H+V · Rotación $\pm 15^\circ$ · Zoom $\pm 15\%$ · Traslación $\pm 10\%$	Más agresivo que el baseline porque el dataset sigue siendo pequeño; mayor variedad reduce el sobreajuste.
Sin aug. brillo/contraste	—	Los personajes 2D tienen colores planos y saturados que son características discriminativas clave; alterarlos introduce ruido sin valor semántico.
BN del backbone	Siempre en modo inferencia (training=False)	Preserva las estadísticas aprendidas en ImageNet; recalcularlas con ~190 muestras las degradaría.
GlobalAvgPooling2D	Reduce ($5 \times 5 \times 1280$) a vector de 1280	Reduce parámetros respecto a Flatten y es espacialmente invariante, lo que favorece la generalización.

Componente	Configuración	Justificación
Dense(128, ReLU) + L2	Regularización L2, lambda = 1e-4	Penaliza pesos grandes en la cabeza clasificadora, reduciendo el sobreajuste con pocos datos.
Dropout	Tasa 0.4 (vs 0.5 en baseline)	Algo menor porque L2 ya aporta regularización adicional; combinar ambas evita regularizar en exceso.
Fase 1 — lr	1e-3, máx. 15 épocas	LR estándar; el backbone está congelado y solo se ajusta la cabeza.
Fase 2 — lr	1e-4, máx. 25 épocas	LR reducido para no destruir las representaciones preaprendidas del backbone.
Fine-tune desde capa 100	Últimas 54 capas libres (de 154 totales)	Las capas inferiores detectan features genéricos (bordes, texturas) útiles en cualquier dominio; no necesitan adaptarse al dominio.
Callbacks	EarlyStopping ReduceLROnPlateau ModelCheckpoint	Evitan el sobreentrenamiento, adaptan el lr cuando el progreso se estanca y conservan el mejor modelo de cada fase.

Tabla 4. Decisiones de diseño del modelo de Transfer Learning.

6. Métricas de desempeño

Para evaluar el desempeño se emplean métricas estándar de clasificación binaria, calculadas sobre el conjunto de test con promedio ponderado (weighted average):

- **Accuracy:** proporción de predicciones correctas sobre el total.
- **Precision:** de las predicciones positivas, cuántas son correctas.
- **Recall:** de los positivos reales, cuántos se detectan.
- **F1-score:** media armónica de precision y recall.
- **Matriz de confusión:** distribución detallada de aciertos y errores por clase.
- **Curva ROC:** capacidad discriminativa del modelo independiente del umbral de clasificación. Se añade en el modelo de transfer learning porque su mayor confianza hace que la curva sea informativa; en el baseline con accuracy del 63 % el AUC aportaría poca información adicional.

7. Iteraciones realizadas

El desarrollo siguió un proceso iterativo que partió del baseline e incorporó mejoras justificadas por el análisis de cada etapa anterior.

Iteración	Cambio introducido	Justificación	Resultado
1 — CNN baseline	CNN desde cero con augmentation ligero.	Establecer una referencia mínima funcional sobre la que medir mejoras posteriores.	Accuracy 63.4 %. Sobreajuste evidente: la pérdida de validación oscila mientras la de entrenamiento descende.
2 — MobileNetV2 Fase 1	Backbone congelado; solo se entrena la nueva cabeza clasificadora.	El sobreajuste del baseline indica que el dataset es insuficiente para aprender features desde cero. Las representaciones de ImageNet compensan la escasez de datos.	Mejora sustancial sobre el baseline. Entrenamiento estable y rápido.
3 — Fine-tuning Fase 2	Descongelado de las últimas 54 capas del backbone con $lr = 1e-4$.	Las capas superiores detectan patrones específicos del dominio; adaptarlas al estilo visual de Los Simpsons mejora la especificidad sin perder los features genéricos de las capas inferiores.	Accuracy final 90.2 %. Mejora adicional de ~12 pp respecto a Fase 1.
Descartado — Aug. brillo	Variaciones de brillo y contraste en el pipeline de augmentation.	Los personajes 2D tienen colores planos y saturados que son características discriminativas clave; alterarlos introduce ruido sin variedad útil.	No implementado.
Descartado — Fine-tuning total	Descongelar todas las capas del backbone.	Con 190 muestras de entrenamiento, ajustar todos los parámetros destruiría los features genéricos de las capas inferiores sin datos suficientes para reaprender representaciones útiles.	No implementado.
Descartado — Batch size 32	Usar batch size de 32.	Con 190 muestras, un batch de 32 reduciría a solo 6 los pasos de gradiente por época. Un batch de 8 cuadruplica las actualizaciones.	Se usó batch size 8.

Tabla 5. Iteraciones realizadas y decisiones descartadas con su justificación.

8. Resultados

8.1 Comparativa de métricas en test

Ambos modelos se evaluaron sobre el mismo conjunto de test (15 % del dataset, split estratificado). Las métricas corresponden al promedio ponderado sobre ambas clases.

Métrica	CNN Baseline	MobileNetV2 TL	Mejora absoluta
Accuracy	63.41 %	90.24 %	+26.83 pp
Precision	63.76 %	90.30 %	+26.54 pp
Recall	63.41 %	90.24 %	+26.83 pp
F1-score	0.6355	0.9030	+0.2675

Tabla 6. Métricas de evaluación en el conjunto de test.

8.2 Análisis de los resultados

El modelo de transfer learning supera al baseline en todas las métricas por un margen de más de 26 puntos porcentuales. Este resultado es coherente con la literatura: cuando el dataset de entrenamiento es pequeño, aprovechar representaciones visuales preaprendidas en grandes corpora compensa eficazmente la escasez de datos propios.

Las curvas de aprendizaje muestran que la Fase 1 converge de forma estable y sin sobreajuste significativo, validando la decisión de comenzar con el backbone congelado. La Fase 2 produce una mejora adicional gradual con tasa de aprendizaje reducida, sin degradar las representaciones aprendidas en la fase anterior.

El análisis mediante Grad-CAM confirma que el modelo focaliza su atención en las características visuales propias de cada personaje; forma y color de la cabeza, ropa, rasgos faciales, indicando que la clasificación tiene base semántica y no es resultado de memorizar patrones del fondo, además, justifica muchos de los casos mal clasificados, pues si se revisa la imagen procesada, se puede identificar la falta de estas características visuales.

El bajo rendimiento del baseline (63.4 %) se explica por la combinación de un dataset pequeño y el entrenamiento desde cero: la red no dispone de suficientes ejemplos para aprender representaciones visuales discriminativas, generando el sobreajuste observado.

8.3 Artefactos generados

Archivo	Descripción	Notebook
best_baseline_cnn.keras	Mejor modelo CNN baseline (menor val_loss)	01
curvas_baseline.png	Curvas de pérdida y accuracy del baseline	01
confusion_matrix_baseline.png	Matriz de confusión del baseline	01
predicciones_baseline.png	Visualización de 16 predicciones en test	01
mobilenet_fase1.keras	Mejor modelo Fase 1 (backbone congelado)	02
mobilenet_fase2_best.keras	Mejor modelo Fase 2 (fine-tuning parcial)	02
augmentation_examples.png	Ejemplos del efecto de data augmentation	02
curvas_transfer_learning.png	Curvas de aprendizaje de ambas fases	02
confusion_matrix_transfer.png	Matriz de confusión del modelo TL	02

Archivo	Descripción	Notebook
roc_curve.png	Curva ROC con AUC del modelo MobileNetV2	02
gradcam_resultados.png	Mapas de calor Grad-CAM sobre predicciones	02
comparacion_modelos.png	Gráfica comparativa baseline vs Transfer Learning	02

Tabla 7. Artefactos generados durante la ejecución de los notebooks.

9. Conclusiones y trabajo futuro

9.1 Conclusiones

El proyecto demuestra que el Transfer Learning es la estrategia más efectiva cuando el dataset de entrenamiento es pequeño. La diferencia de 26 puntos porcentuales entre la CNN baseline y MobileNetV2 lo confirma empíricamente: ninguna técnica de regularización aplicada al baseline consiguió compensar la falta de datos para aprender features visuales desde cero.

El fine-tuning parcial sobre las capas superiores del backbone produce una mejora adicional significativa sin degradar las representaciones genéricas de las capas inferiores, validando la estrategia de descongelar solo la parte del modelo que es más específica del dominio.

La data augmentation geométrica resulta eficaz para este dominio, mientras que las variaciones de color se descartaron correctamente: los colores son una característica discriminativa clave de los personajes y alterarlos dificultaría la clasificación.

El análisis Grad-CAM añade valor diagnóstico al verificar que el modelo clasifica por las características visuales del personaje y no por memorización de patrones del fondo, lo que da confianza en la capacidad de generalización del modelo.

9.2 Limitaciones

- El conjunto de test contiene aproximadamente 40 imágenes, lo que introduce varianza elevada en las métricas. Una diferencia de un solo ejemplo supone más de 2 puntos porcentuales en accuracy.
- Se utilizó un único split train/val/test. La validación cruzada k-fold proporcionaría una estimación más robusta del rendimiento real.
- No se realizó búsqueda sistemática de hiperparámetros; los valores empleados se basan en la práctica habitual y ajustes manuales.

9.3 Trabajo futuro

- Explorar EfficientNetB0 o EfficientNetB3, que ofrecen mejor relación accuracy/parámetros que MobileNetV2 en benchmarks estándar.
- Aplicar Mixup o CutMix como técnicas de augmentation a nivel de batch para incrementar la regularización de forma independiente al dominio visual.
- Implementar validación cruzada k-fold para obtener una estimación más fiable del rendimiento generalizable del modelo.

- Ampliar el dataset mediante scraping de fotogramas de la serie o generación sintética con modelos generativos.

10. Referencias

- [1]LeCun, Y., Bottou, L., Bengio, Y., & Haffner, P. (1998). Gradient-based learning applied to document recognition. *Proceedings of the IEEE*, 86(11), 2278–2324.
- [2]Krizhevsky, A., Sutskever, I., & Hinton, G. E. (2012). ImageNet classification with deep convolutional neural networks. *Advances in Neural Information Processing Systems*, 25.
- [3]Sandler, M., Howard, A., Zhu, M., Zhmoginov, A., & Chen, L.-C. (2018). MobileNetV2: Inverted residuals and linear bottlenecks. *Proceedings of the IEEE CVPR*.
- [4]Selvaraju, R. R., Cogswell, M., Das, A., Vedantam, R., Parikh, D., & Batra, D. (2017). Grad-CAM: Visual explanations from deep networks via gradient-based localization. *Proceedings of the IEEE ICCV*.
- [5]He, K., Zhang, X., Ren, S., & Sun, J. (2016). Deep residual learning for image recognition. *Proceedings of the IEEE CVPR*.